Hierarquia de Memória I

Prof. Gustavo Girão

*Baseado no material do Professor Leandro Galvão

Plano de Aula

- Motivação
- Introdução
- Hierarquia de memória
- Memória cache

Introdução

- Memória:
  - Pode ser definida como um local para armazenamento de informações, onde as duas únicas ações possíveis são a leitura e a escrita.
  - A informação pode ser representada pelo bit ou por um conjunto de n bits que possuem um endereço definido.
  - Em um sistema computacional, temos diferentes tipos de memórias, para diferentes finalidades, que se interligam de forma estruturada e que formam o subsistema de memória.

EM UM CENÁRIO IDEAL, ONDE PREÇO NÃO É UM PROBLEMA, QUAL O TAMANHO E A LOCALIZAÇÃO DA MEMÓRIA EM UM COMPUTADOR?

Hierarquia de Memória

- Queremos memórias grandes e velozes, mas elas são caras
- O que temos são diferentes tecnologias de memória onde as mais velozes são mais caras e as mais baratas são mais lentas
- Essas memórias podem ser distribuídas dentro da arquitetura do computador
- A solução está em fazer com que as diferentes memórias combinadas pareçam ser uma memória grande e veloz a um custo razoável

Memory Wall

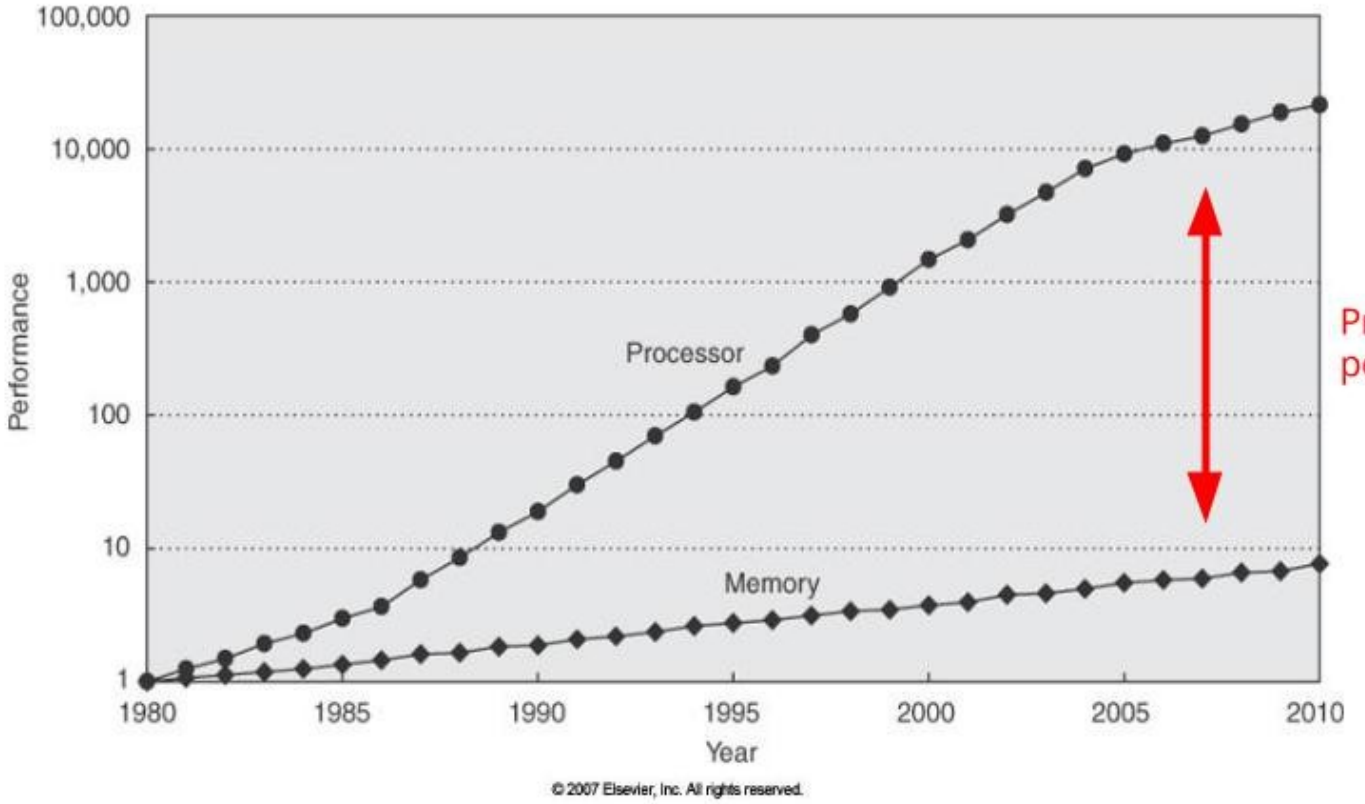

Memory speed lags behind CPU speed

Hierarquia de Memória

- Hierarquia de Memória
  - Inclusiva: cada nível é um sub-conjunto do nível inferior

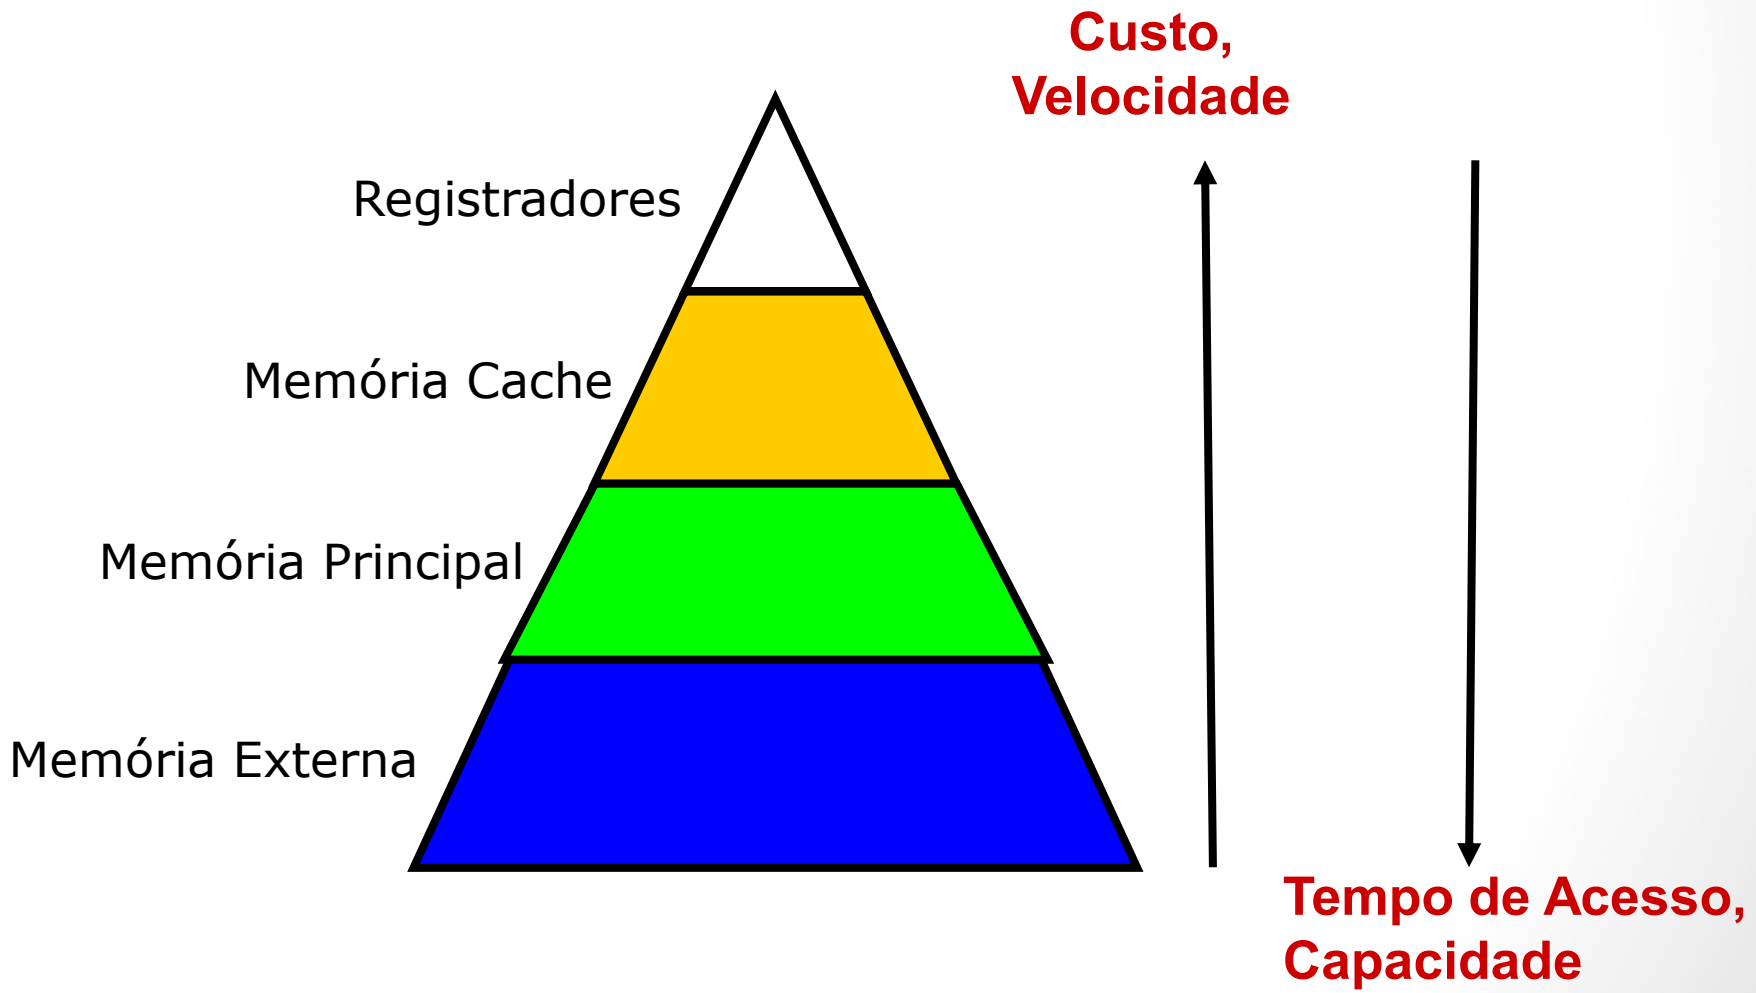

Hierarquia de Memória

- Hierarquia de Memória
  - Componentes tecnológicos

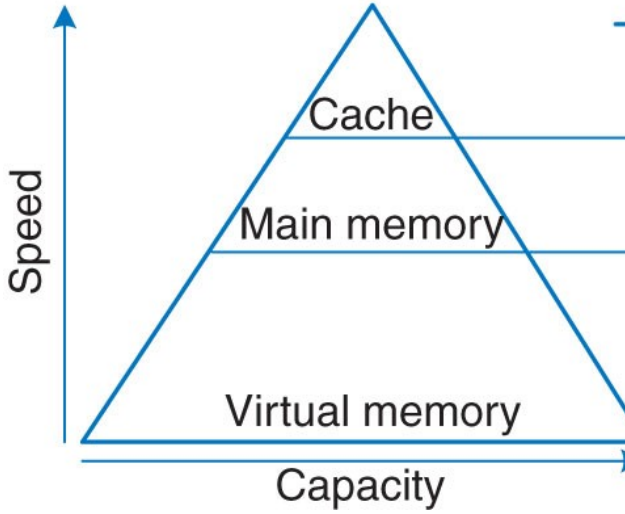

Technology	Price / GB	Access Time (ns)	Bandwidth (GB/s)
SRAM	$10,000	1	25+
DRAM	$10	10–50	10
SSD	$1	100,000	0.5
HDD	$0.1	10,000,000	0.1

Quem são?

- Caches

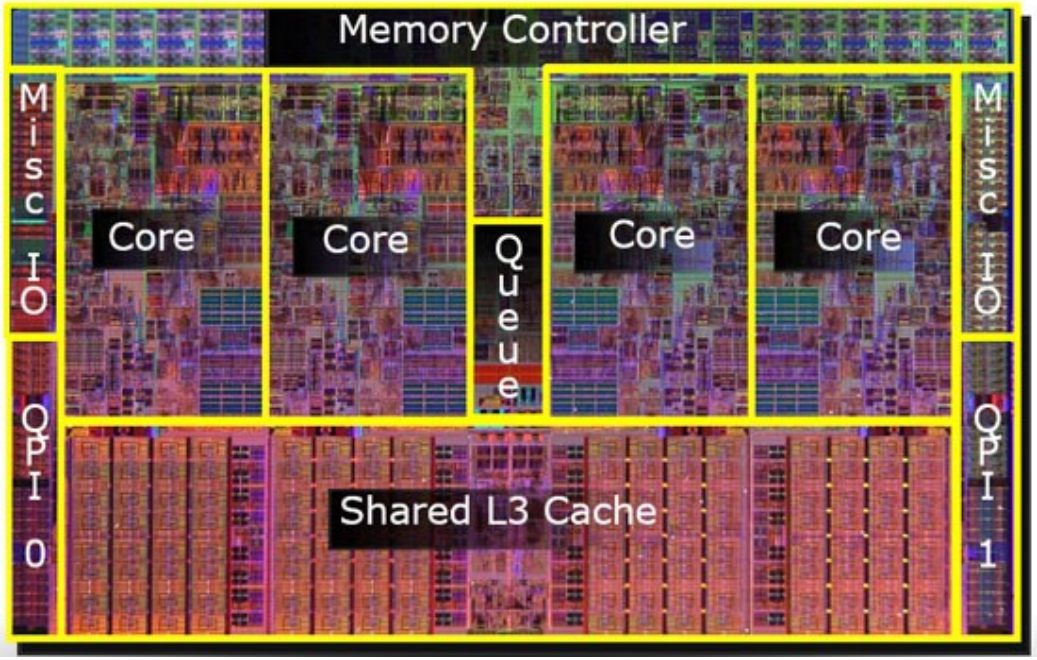

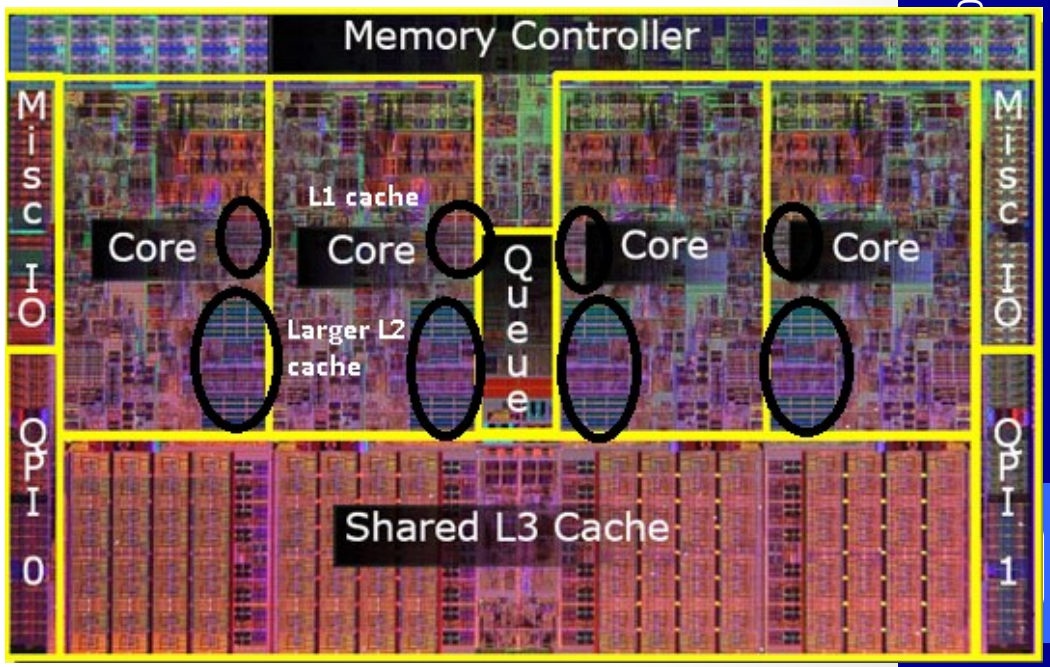

Quem são?

- Memória Principal
  - Memória RAM

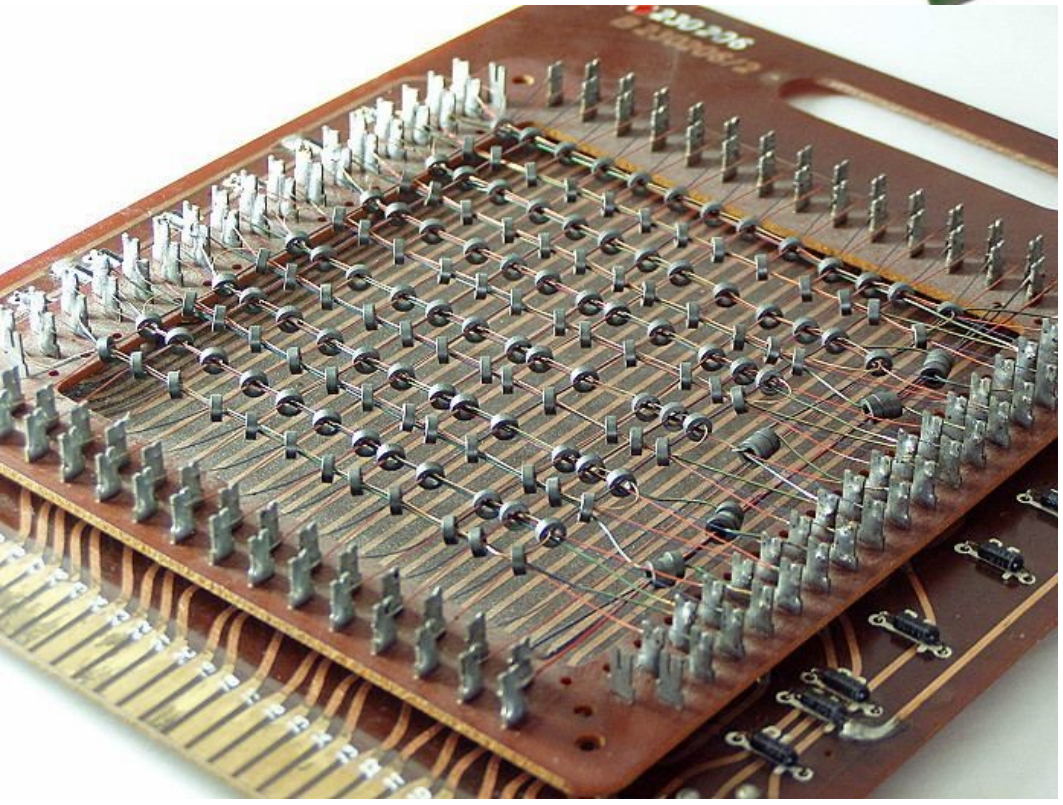

Quem são?

- Memória Secundária
- Discos, Fitas, Cartões

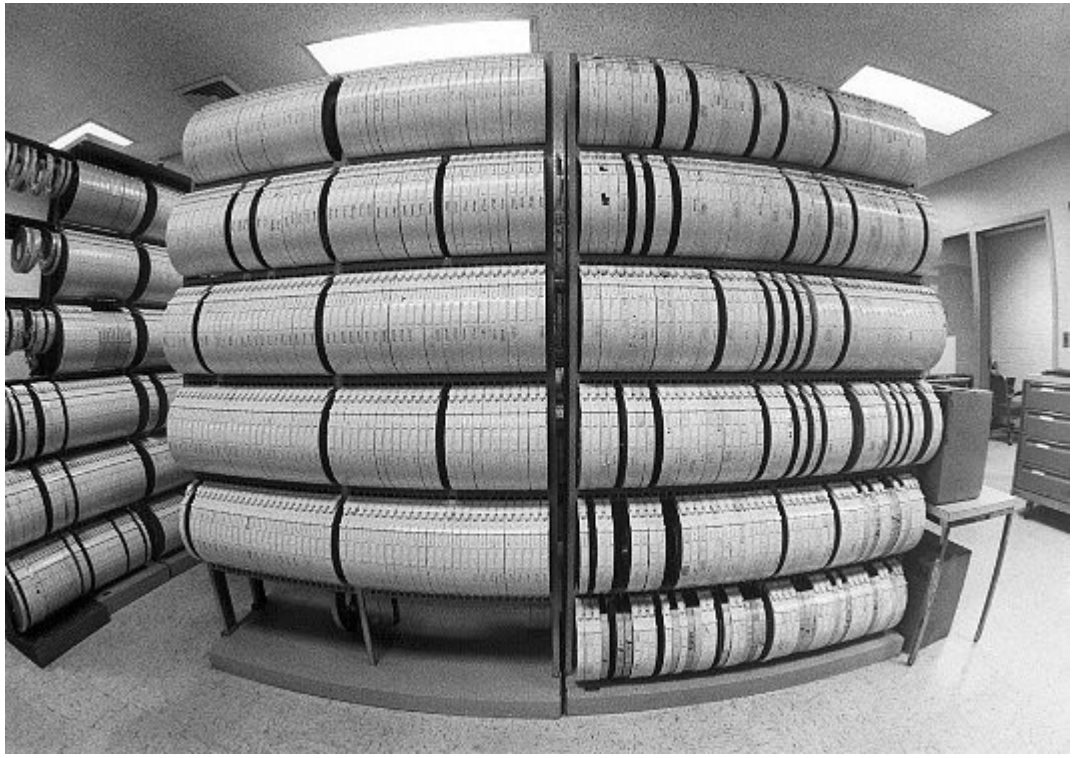

Hierarquia de Memória

- Tamanhos e latência
  - Para servidores

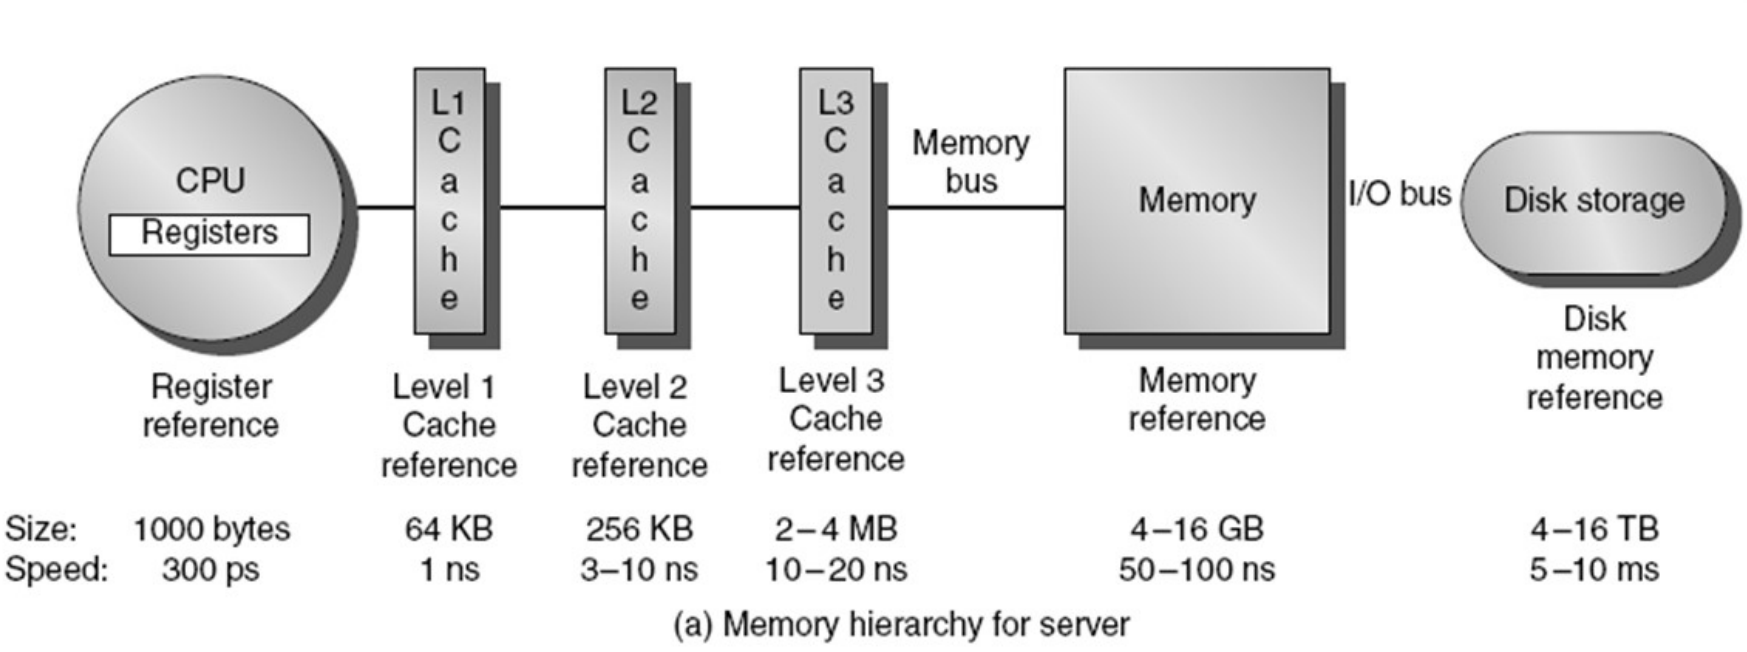

(a) Memory hierarchy for server

Hierarquia de Memória

- Tamanhos e latência
  - Para dispositivos móveis

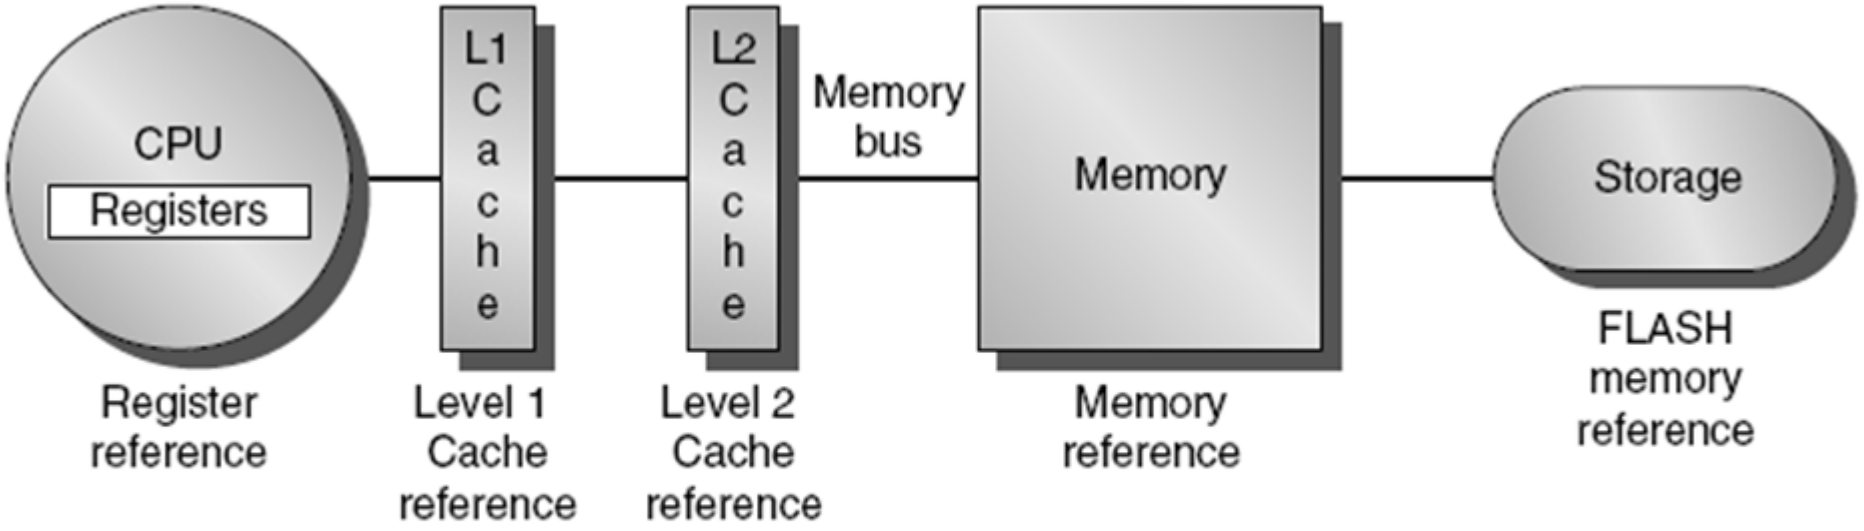

(b) Memory hierarchy for a personal mobile device

Hierarquia de Memória

- Os dados contidos num nível mais próximo do processador são sempre um sub-conjunto dos dados contidos no nível anterior. (hierarquia de memória inclusiva!)
- O nível mais baixo contém a totalidade dos dados.

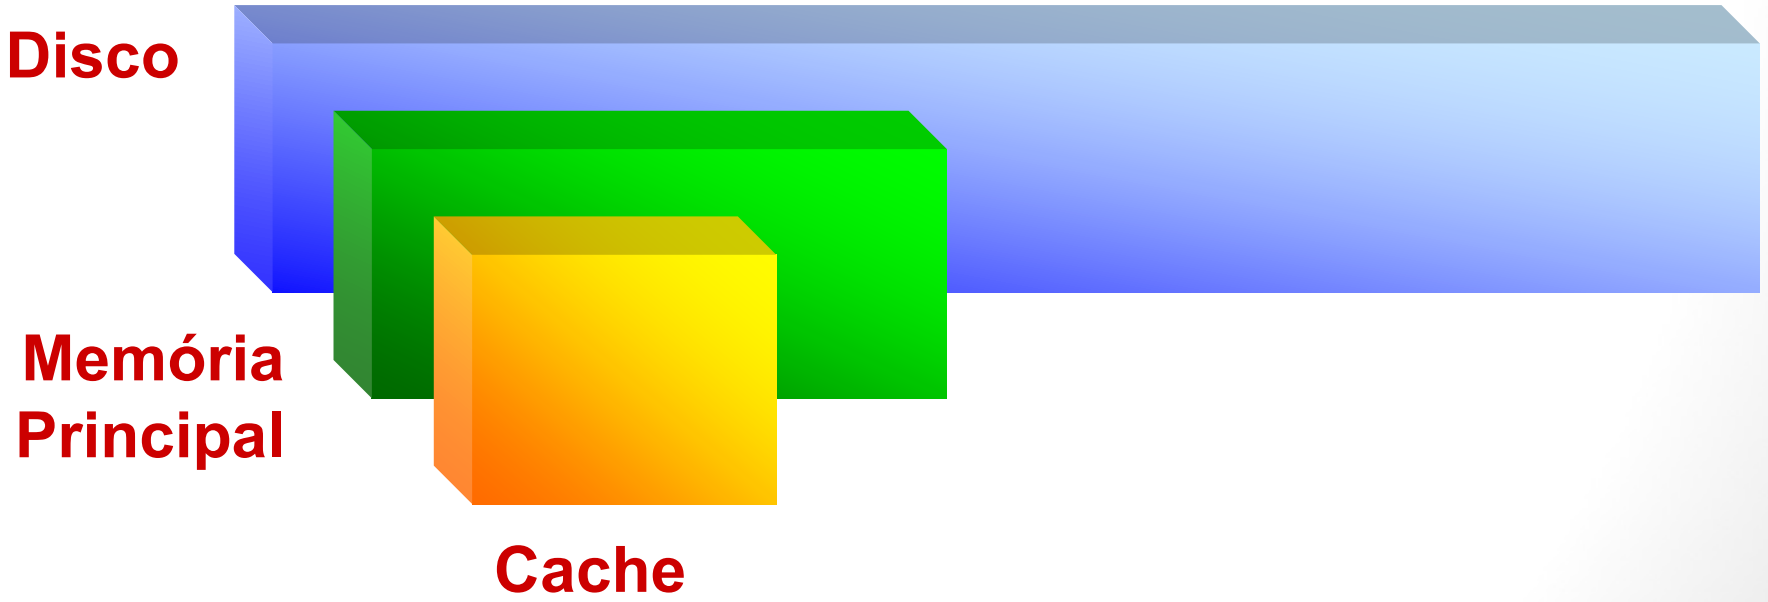

Atenção

- Memória Primária (principal): memória que o processador pode endereçar diretamente;

- Memória Secundária: não podem ser endereçadas diretamente. Ou seja, a informação precisa ser primeiro carregada na memória principal para depois ser enviada para a memória secundária.

Cache Hit e Cache Miss

- Quando o processador busca uma informação (dado ou instrução) na memória principal, ele vai primeiro na cache

- Se a informação está na cache, chama-se *cache hit*
  - A informação é buscada e será usada pelo processador

- Se a informação NÃO está na cache, chama-se *cache miss*
  - A informação precisa ser buscada na memória principal

Operação da Hierarquia de Memória

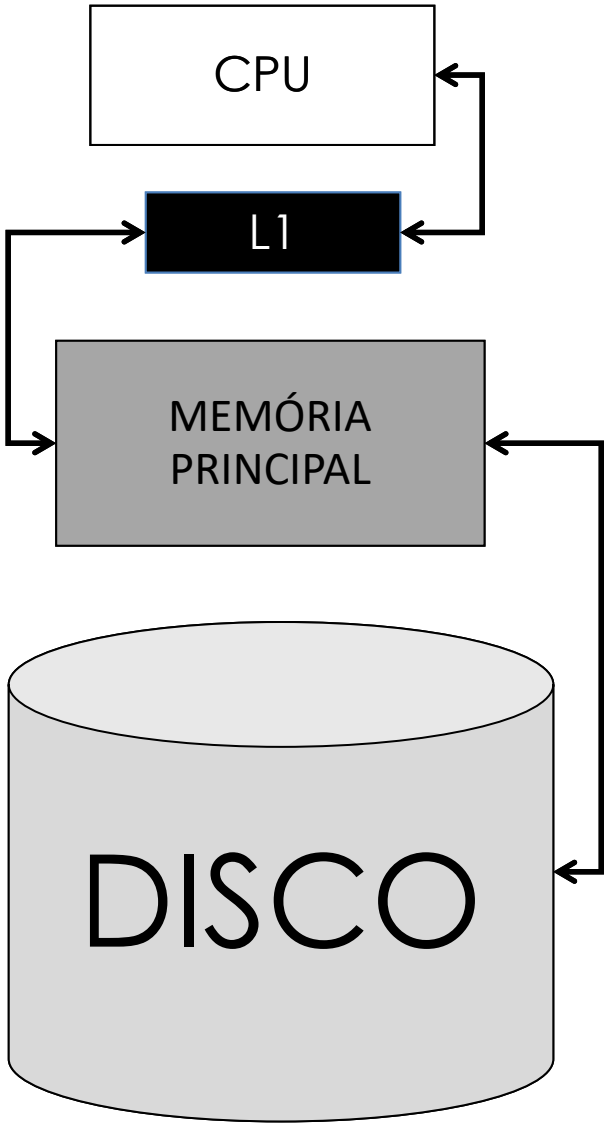

1. Acessa L1 p/ instrução ou dado. Se encontra a informação (cache hit), executa;

2. Senão (cache miss), busca na memória principal. Se acha, coloca em L1 e repete o passo 1;

3. Senão, obtém através de E/S.

Operação da Hierarquia de Memória

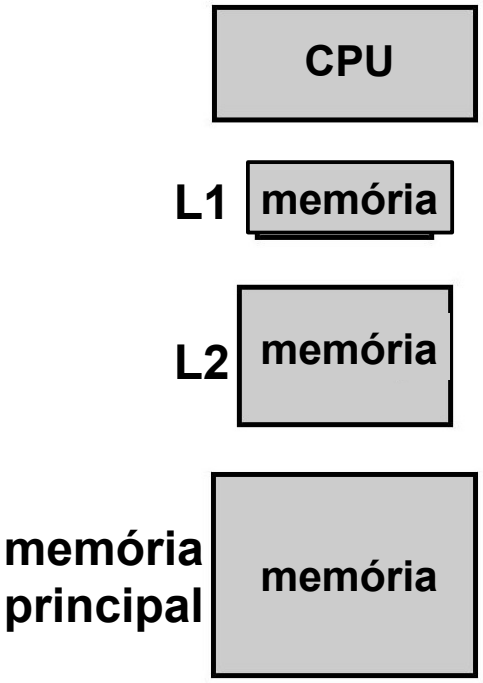

(1) Busca L1 p/ instrução ou dado.
Se acha (*cache hit*), executa.

(2) Senão (*cache miss*), busca L2.
Se acha, coloca em L1 e repete (1).

(3) Senão, busca na memória principal.
Se acha, coloca em L2 e repete (2).

(4) Senão, obtém através de I/O.

Passos (1) - (3) são executados em hardware:

- 1-3 ciclos p/ obter da cache L1.
- 5-20 ciclos p/ obter da cache L2.
- 50-200 ciclos p/ obter da memória principal.

Passo (4) é executado pelo SO

Princípio da Localidade

- Localidade: estatística de comportamento do acesso aos dados da memória.

- Se um item é referenciado,
  - Ele tende a ser referenciado em breve novamente
  - Os itens na sua vizinhança também o serão

Princípio da Localidade

O princípio da localidade faz com que a hierarquia de memória funcione na prática.

Localidade

- Localidade temporal:
  - Um item referenciado tende a ser referenciado novamente em um curto espaço de tempo

EXEMPLO?

- Localidade espacial:
  - Os itens próximos na memória a um item referenciado tendem a ser também referenciados

EXEMPLO?

Localidade

- Localidade temporal:
  - Um item referenciado tende a ser referenciado novamente em um curto espaço de tempo
  - Ex: loops

- Localidade espacial:
  - Os itens próximos na memória a um item referenciado tendem a ser também referenciados
  - Ex: matrizes e estruturas

Localidade – Exemplo 1

```
int soma_linhas(int a[M][N]) {
    int i, j, sum = 0;
    for (i = 0; i < M; i++)
        for (j = 0; j < N; j++)
            sum += a[i][j];
    return sum;
}
```

- Localidade temporal:
  Mesmas instruções são executadas seguidamente M × N vezes.

- Localidade espacial:
  Percorre-se a matriz linha a linha.
  Assim, faz-se sempre acesso a posições de memória contíguas.

Localidade – Outro Exemplo

Baixa Localidade Temporal

Baixa Localidade Espacial

Exemplo 2 – Baixa L. Espacial

```
int soma_coluna(int a[M][N]) {
    int i, j, sum = 0;
    for (j = 0; j < N; j++)
        for (i = 0; i < M; i++)
            sum += a[i][j];
    return sum;
}
```

- Localidade temporal:
  - Mesmas instruções são executadas seguidamente M × N vezes.
- Localidade espacial:
  - Percurso da matriz é feito coluna a coluna
  - Portanto, dois acessos consecutivos não fazem acesso a posições de memória contíguas.

Memória Cache

- Memória rápida e de pequena capacidade.
- Guarda somente os itens que serão referenciados com frequência em determinado momento.
- Para tal, explora os conceitos de Localidade Temporal e de Localidade Espacial.
- Tais itens podem ser tanto dados, como instruções.

Memória Cache

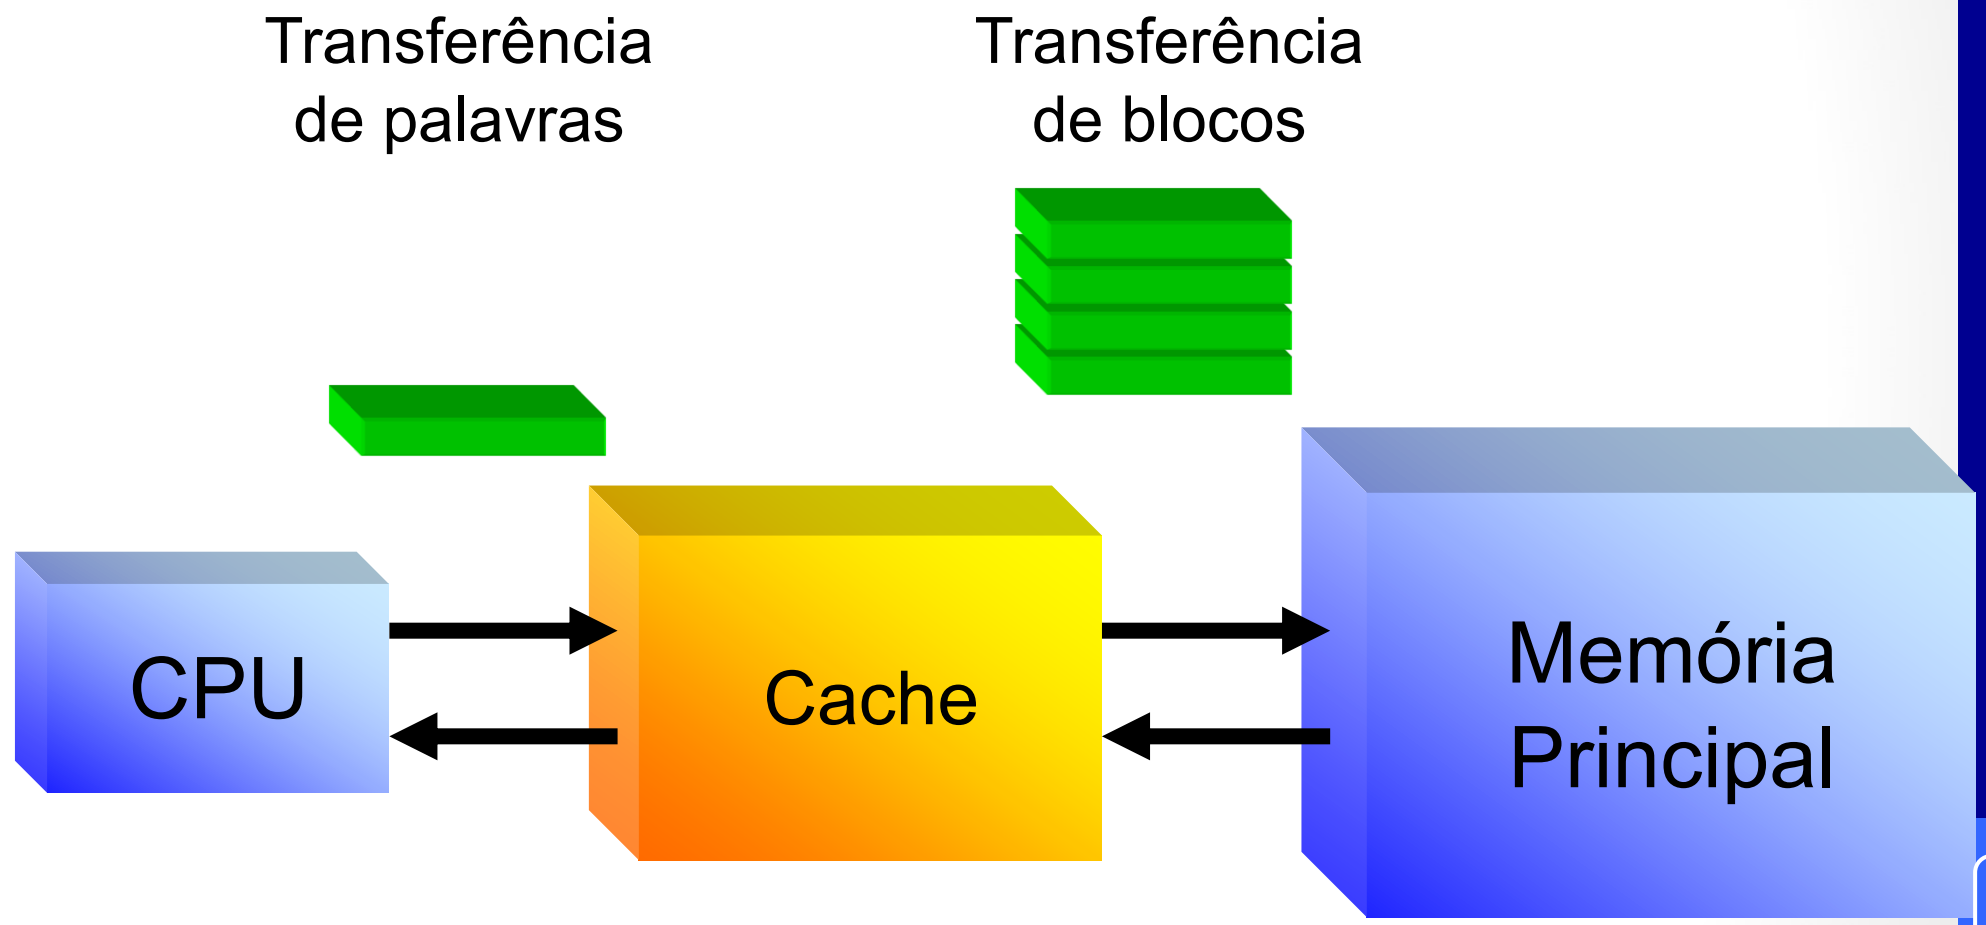

Divisão da Memória

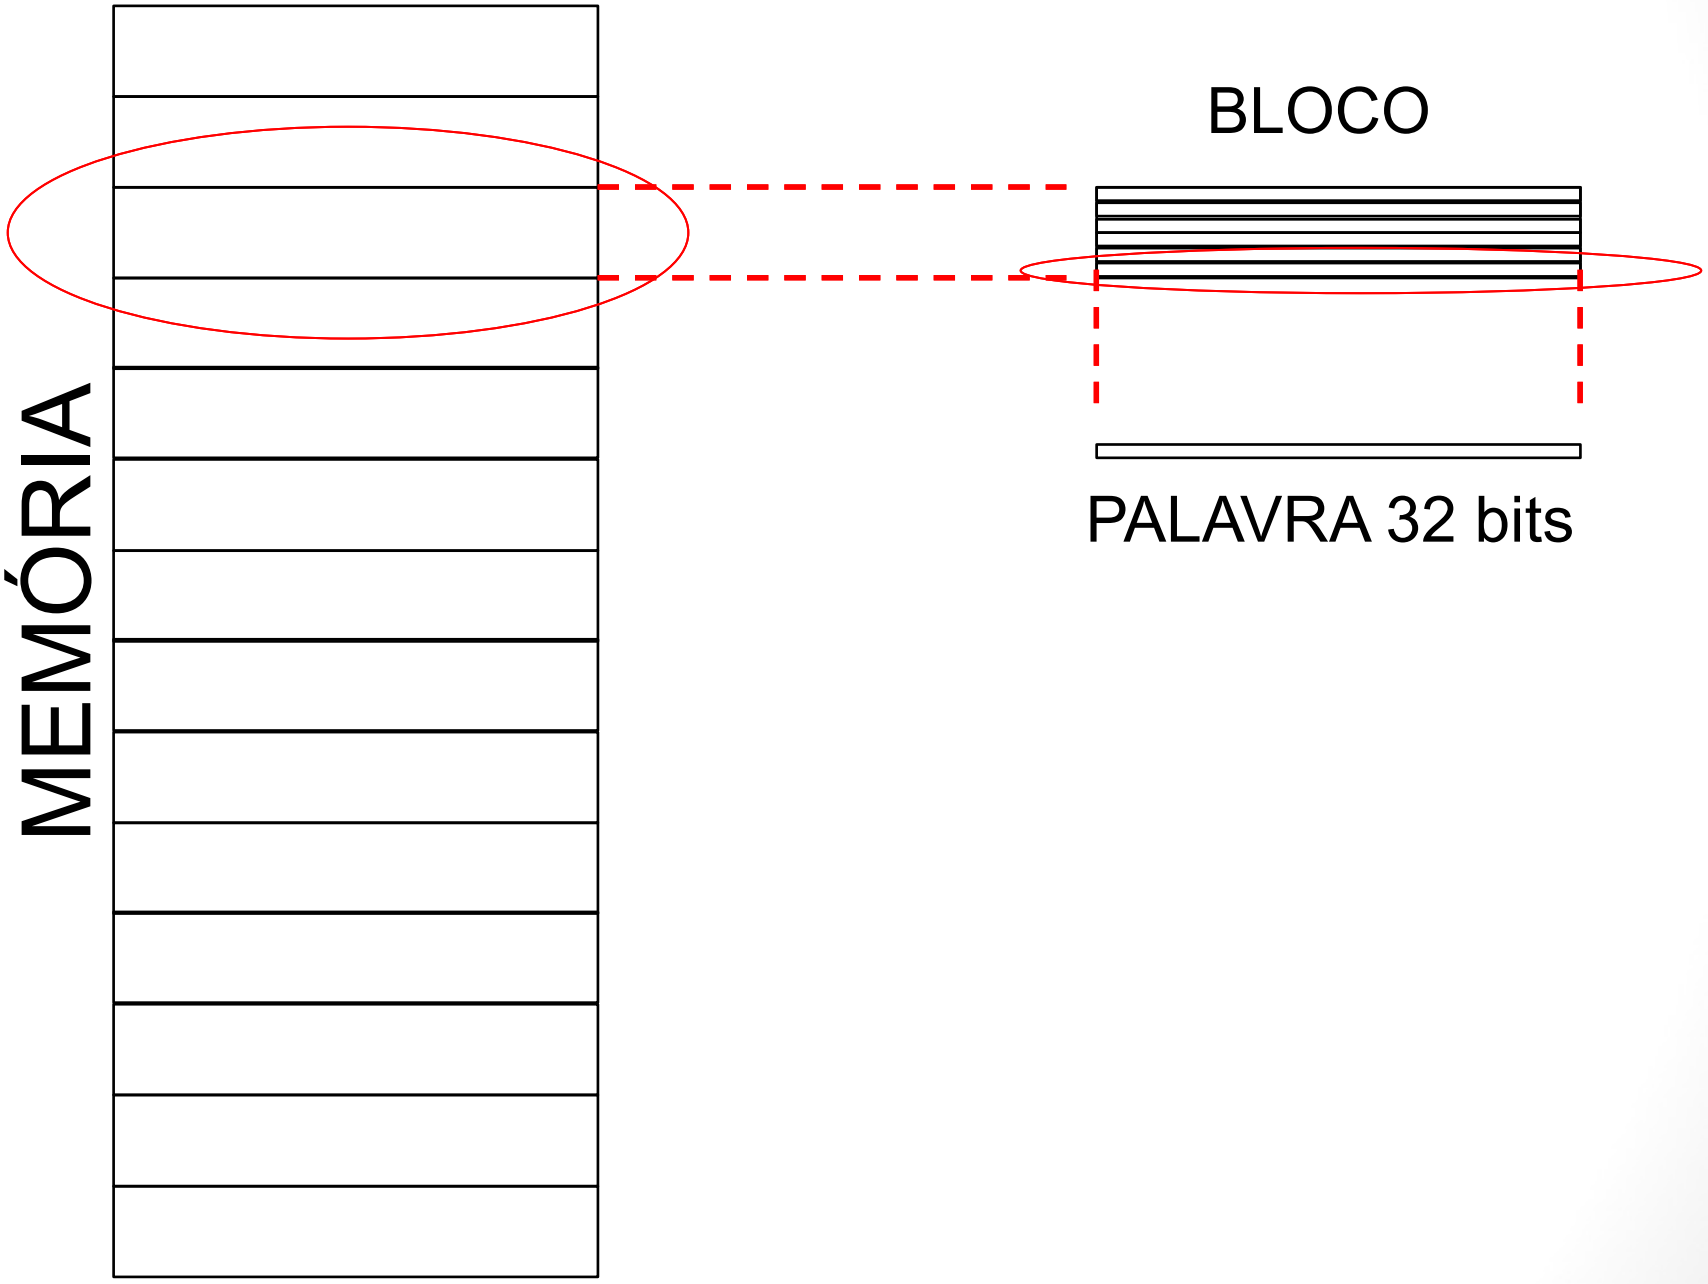

Divisão da Memória

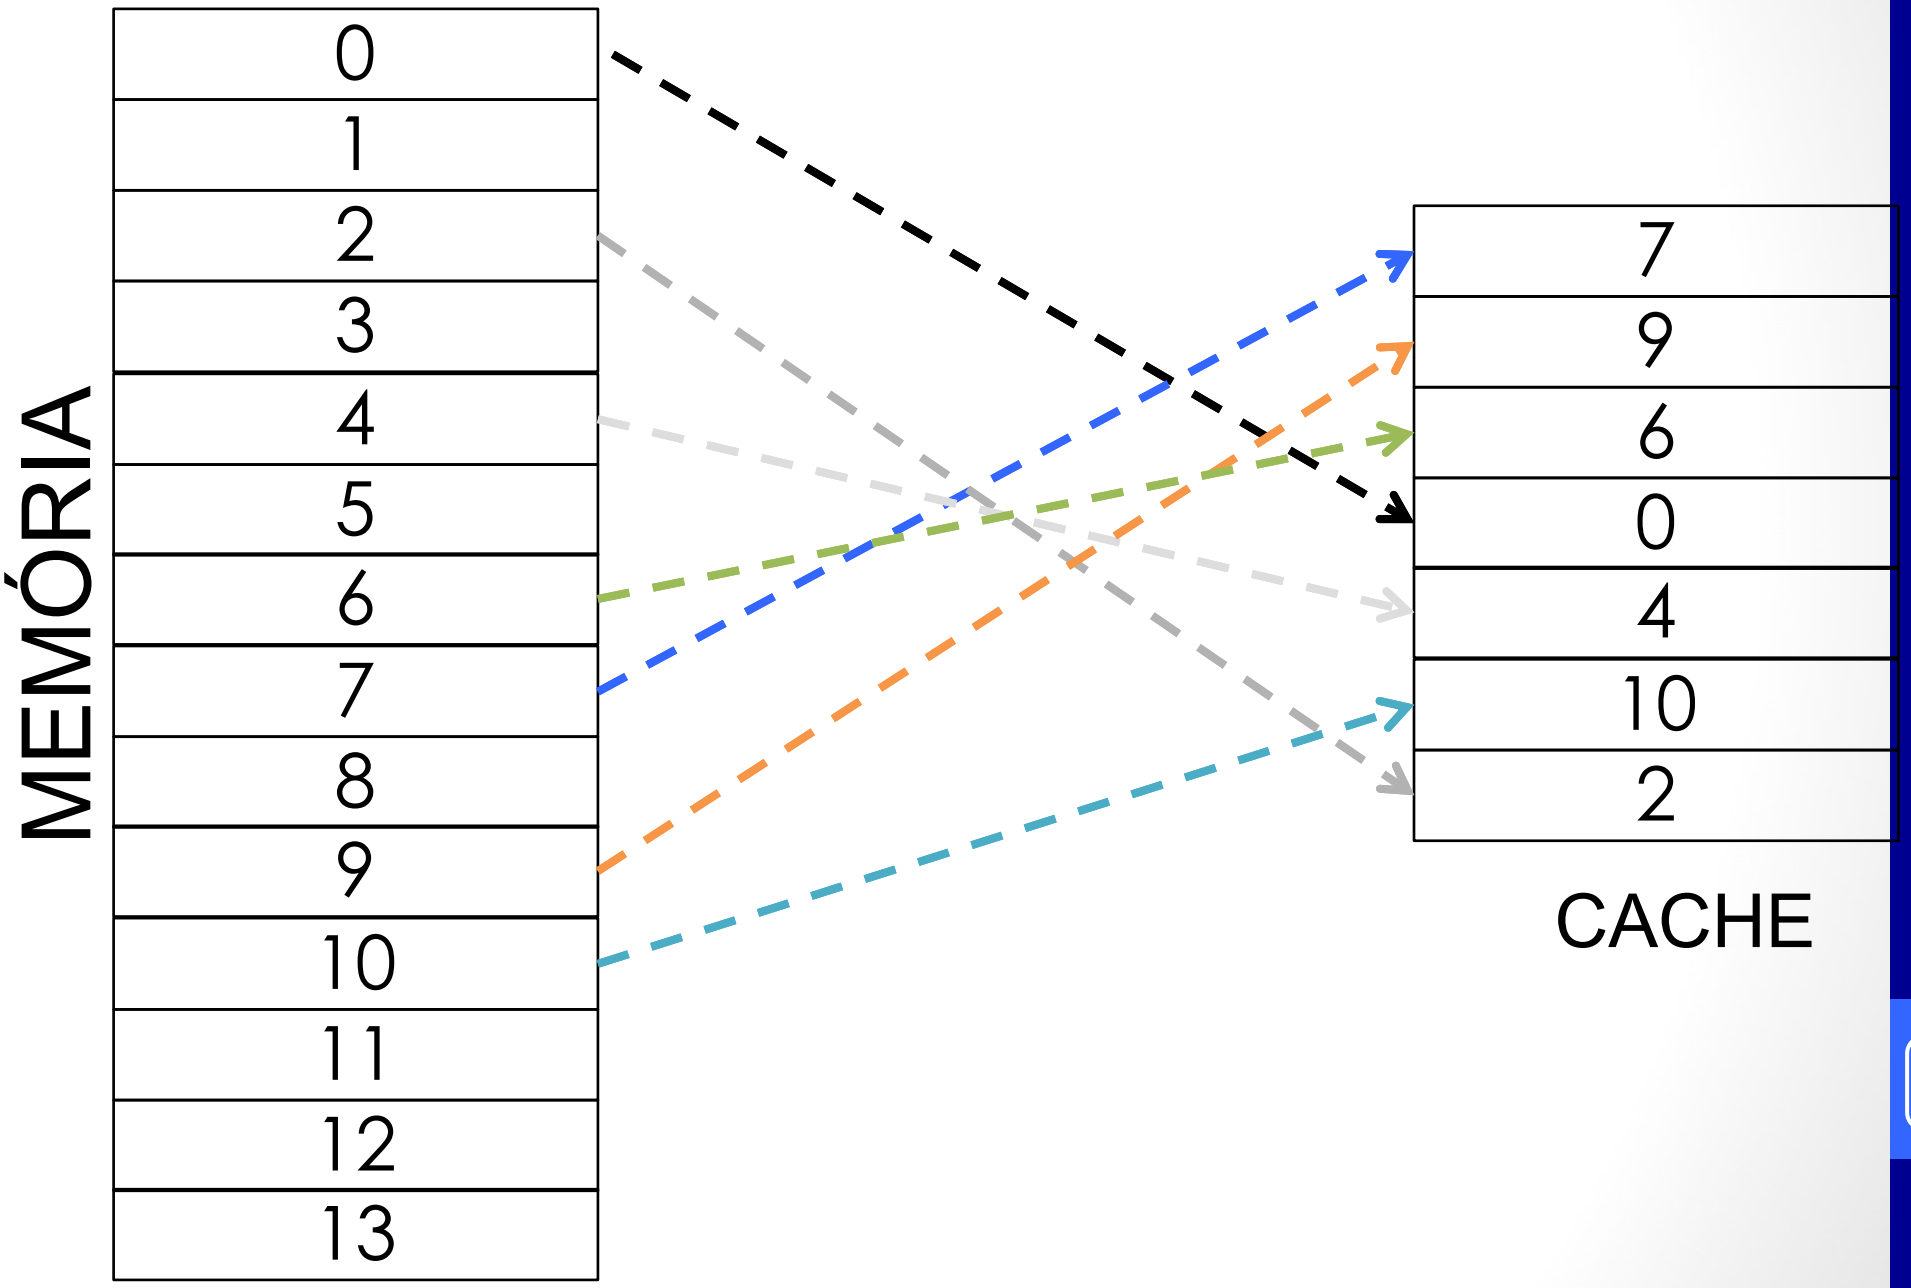

Divisão da Memória

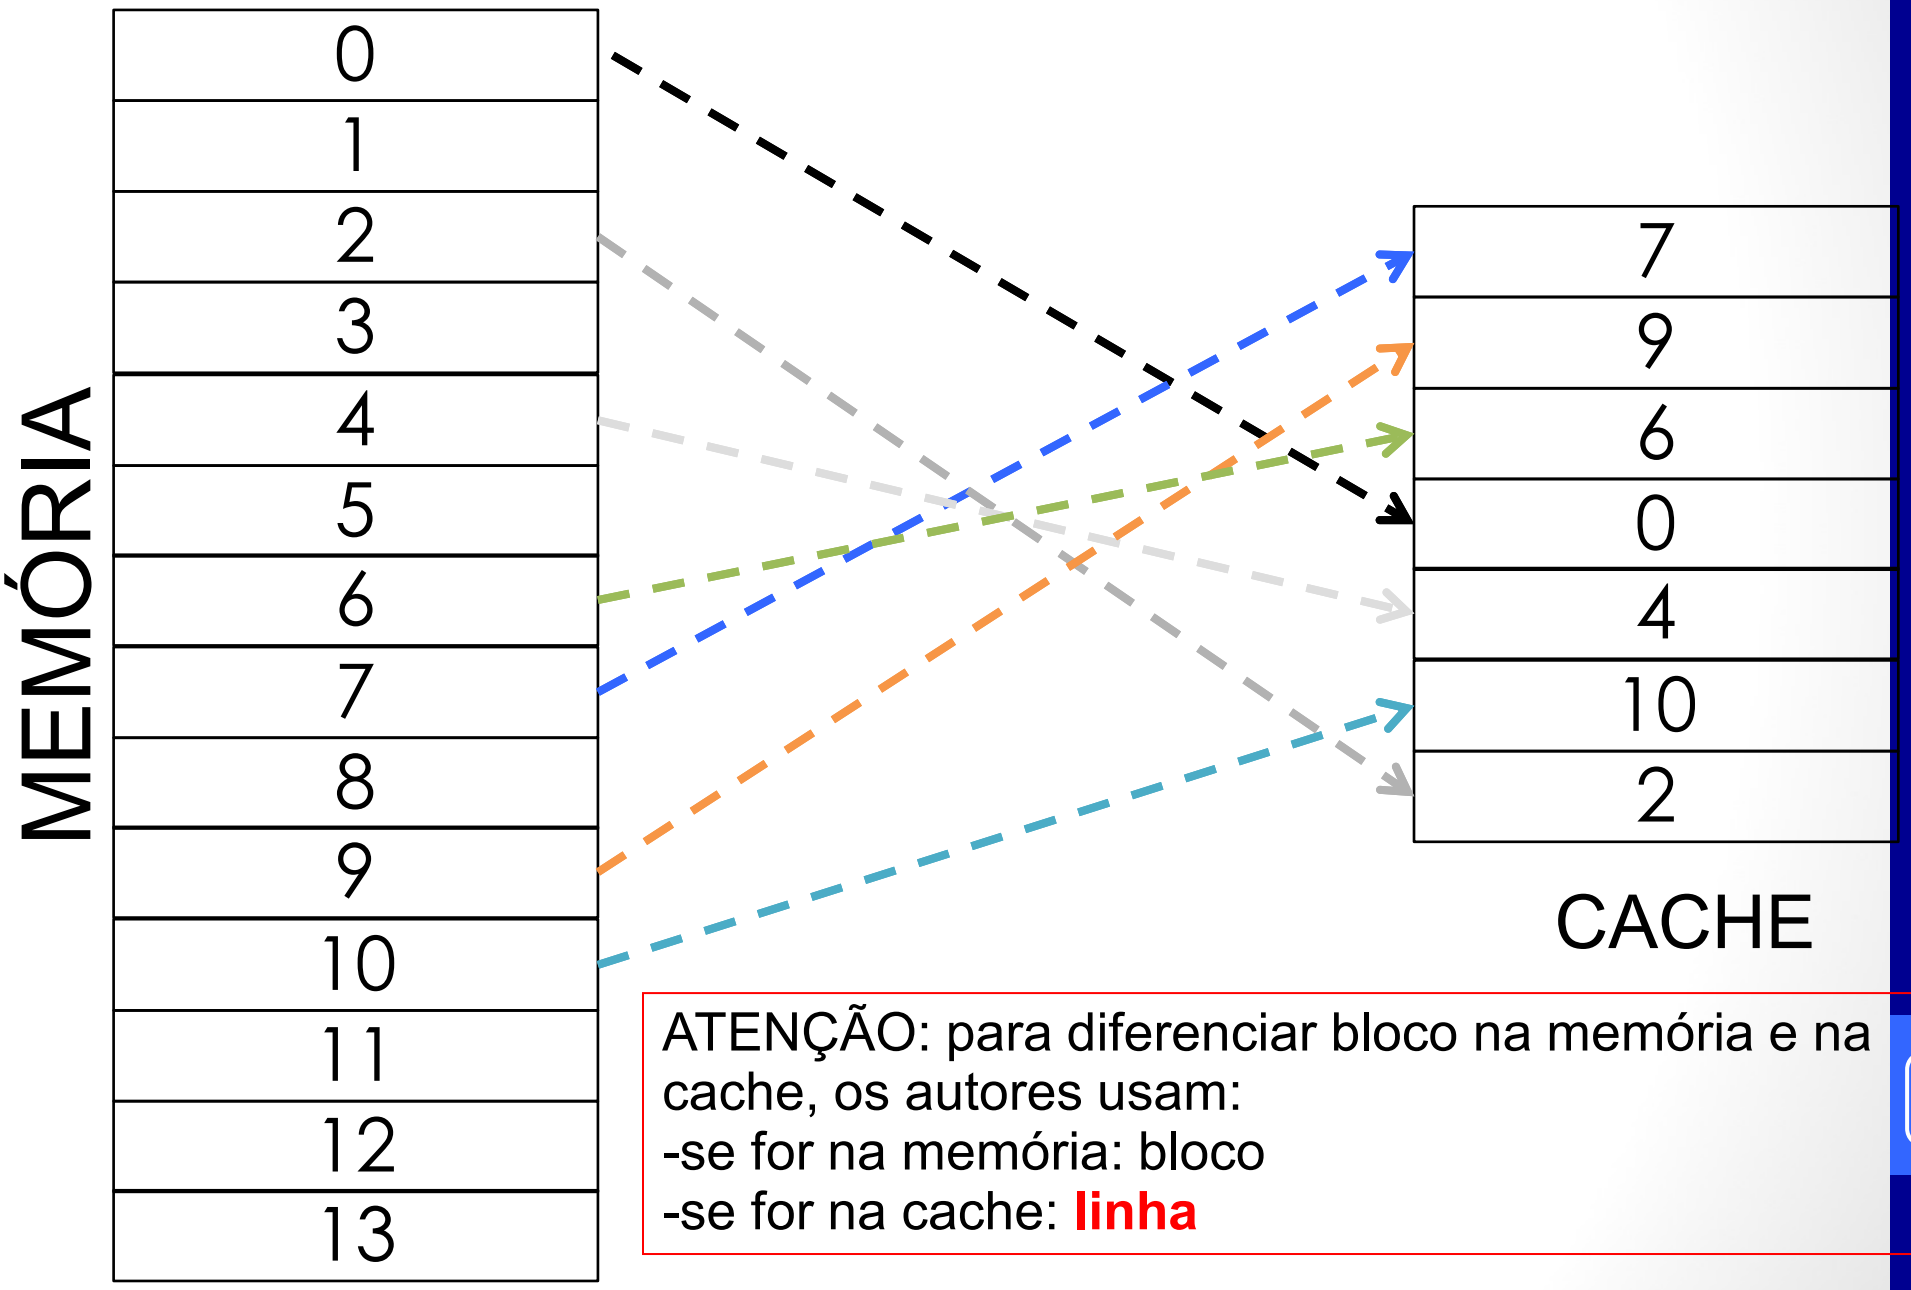

ATENÇÃO: para diferenciar bloco na memória e na cache, os autores usam:
-se for na memória: bloco
-se for na cache: **linha**

Terminologia

- Taxa de hit (hit rate):
  % de hits ocorridos em relação ao total de acessos à memória
- Taxa de miss (miss rate):
  % de misses ocorridos em relação ao total de acessos à memória. Igual a 1-hit rate
- Tempo de hit (hit time):
  tempo para determinar se o acesso é um hit +
  tempo para acessar e entregar o dado de um nível inferior p/ CPU
- Penalidade de miss (miss penalty):
  tempo para determinar se o acesso é um miss +
  tempo para substituir o bloco no nível inferior +
  tempo de entregar o bloco á CPU

Terminologia

- Palavra:
  Unidade do sistema. Algumas memórias podem ser acessadas por byte ao invés de palavra.
- Bloco:
  Um coletivo de palavras dentro da **memória**
- Linha:
  Um coletivo de palavras dentro da **cache.** Para facilitar, todo sistema adota o mesmo tamanho de Bloco para a Linha.
- Tag:
  Identificador único de um Bloco da memória. Utilizado para rotular a linha da cache identificando assim o bloco que atualmente está lá

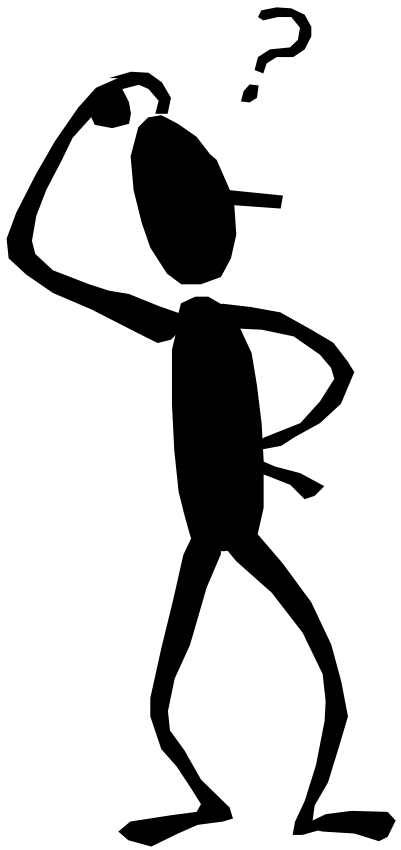

Bibliografia

- PATTERSON, D.A. & HENNESSY, J. L. **Organização e Projeto de Computadores** - A Interface Hardware/Software. 3ª ed. Campus, 2005. **CAPÍTULO 7**

- STALLINGS, William. Arquitetura e organização de computadores. 8. ed. São Paulo: Pearson, 2010. **Capítulo 4**

Próxima aula

- Memória Virtual!